

## Previsão da nota do IDEB

Escolas públicas de ensino médio

Clara Freitas · Flávia Rosa · Itagiba Neto

Bruno Presley · Leonardo Castro

Pós-Graduação em Data Science — SENAC

github



# De onde vem a nota do IDEB?

## INEP



Responsável por pesquisas e avaliações educacionais



## CENSO ESCOLAR

Escolas, infraestrutura e aprovação



## SAEB

Avaliação da aprendizagem

## IDEB

Desempenho no Saeb + taxa de aprovação do Censo

### NOSSO PROJETO

Com as informações das escolas, nosso grupo vai fazer duas análises: usar regressão para estimar a nota do IDEB e usar classificação para prever em qual faixa de nota a escola se encontra.



É possível prever o IDEB de uma escola  
a partir do Censo Escolar?

# O problema

## IDEB

Índice de Desenvolvimento da Educação Básica — combina aprovação (fluxo) e desempenho no SAEB, em escala de 0 a 10.

## Censo Escolar

Levantamento anual do INEP: infraestrutura, equipamentos, profissionais e modalidades de ensino de cada escola.

### Duas abordagens supervisionadas:

- **Regressão** — prever a nota do IDEB\_2025 (valor contínuo)
- **Classificação** — prever a faixa de desempenho (II, MI, MM, MS)

## Duas fontes, uma chave

**214.192 escolas**

Censo Escolar 2025 (INEP) · 290 colunas



merge

**22.171 escolas**

IDEB Ensino Médio 2025 · 7 colunas

- Leitura direta do .zip para o Pandas, sem descompactar no disco
- Filtro: somente escolas públicas, que são as avaliadas pelo IDEB
- Chave de junção: **CO\_ENTIDADE** ↔ **Código da Escola**

## Do bruto ao dataset tratado

Censo público

**162.434**

escolas · 232 colunas

IDEB público

**17.583**

escolas com nota

Merge

**17.583**

escolas · 234 colunas


Tratado

**17.583**


escolas · 227 colunas

- **Colunas irrelevantes removidas** — endereço, telefone, município, CNPJ...
- **6 colunas constantes removidas** — ex.: CO\_REDE, IN\_REGULAR (desvio padrão zero)
- **11 colunas com mais de 50% de nulos mantidas** — nulos preenchidos com 9 (código de "não informado")
- **Target IDEB\_2025** — texto com vírgula → convertido para numérico


# O target: IDEB 2025

**4,44**

média

**4,40**

mediana


**0,71**

desvio padrão

**0,8 – 8,1**

faixa observada

## 225 variáveis numéricas, a maioria binária



164

binárias (IN\_\*)


48

quantitativas (QT\_\*)

15

códigos / tipos (TP\_\*, CO\_\*)

# Outliers: dois tipos, duas decisões



**Códigos inválidos → remover**

88888 em contagens: 1.326 linhas (7,5%)


IN\_\* fora de 0/1: 332 linhas

**Outliers por IQR → manter**

São, em geral, escolas grandes reais

Removê-los cortaria dados válidos

## Limpeza orientada pela EDA e diferença regional




### 37 colunas removidas

- 27 quase constantes ( $\geq 99,5\%$ )
- 8 redundantes
- 2 identificadores

Dataset de modelagem  
**15.925 × 190**

Diferença regional clara: CO\_UF segue como variável

# Nenhuma variável sozinha explica o IDEB



$\approx 0,29$

maior correlação individual com o IDEB

2,3%

dos pares de features com  $|r| > 0,3$

0,04


correlação média entre as features

## Decisão: PCA não aplicado

Bartlett não apresentou evidência suficiente contra  $H_0$ ; junto às baixas correlações, não aplicamos PCA.

O IDEB é multifatorial → modelos que capturem interações não lineares.

# Gradient Boosting é o melhor dos 5 algoritmos




## Comparação de Desempenho do Modelo de Machine Learning

| Configuração de Dados            | Perda de Dados | Modelo                                           | Nº Árvores          | RMSE (↓) | MAE (↓) | MAPE (↓) | R2 (↑) |
|----------------------------------|----------------|--------------------------------------------------|---------------------|----------|---------|----------|--------|
| --- Dados Base (0% Perda) ---    |                | Gradient_Boosting(scikit-learn)                  | 100 SciKit-Learn GB | 0.518    | 0.400   | 9.271    | 0.46   |
|                                  |                | Extreme Gradient Boosting(xgboost)               | XGBoost             | 0.533    | 0.412   | 9.548    | 0.43   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | 150 XGBoost RF      | 0.637    | 0.498   | 11.670   | 0.15   |
|                                  |                | Gradient_Boosting(catboost)                      | CatBoost            | 0.524    | 0.407   | 9.174    | 0.45   |
|                                  |                | Gradient_Boosting(scikit-learn)                  | 100 SciKit-Learn GB | 0.612    | 0.395   | 9.137    | 0.47   |
|                                  |                | Extreme Gradient Boosting(xgboost)               | XGBoost             | 0.637    | 0.416   | 9.936    | 0.41   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | 200 XGBoost RF      | 0.637    | 0.498   | 11.670   | 0.18   |
|                                  |                | Gradient_Boosting(catboost)                      | CatBoost            | 0.534    | 0.415   | 9.594    | 0.42   |
| Corte Nota IDEB<br>(3.73 a 5.15) | Perda de 25 %  | Gradient_Boosting(scikit-learn)                  | SciKit-Learn GB ☆   | 0.356    | 0.292   | 6.543    | 0.25   |
|                                  |                | Extreme Gradient Boosting(xgboost)               | XGBoost             | 0.376    | 0.305   | 6.334    | 0.15   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | XGBoost RF          | 0.391    | 0.329   | 7.392    | 0.09   |
|                                  |                | Gradient_Boosting(catboost)                      | CatBoost            | 0.356    | 0.298   | 6.681    | 0.21   |
|                                  |                | Gradient_Boosting(scikit-learn)                  | SciKit-Learn GB ☆   | 0.356    | 0.291   | 6.540    | 0.25   |
|                                  |                | Extreme Gradient Boosting(xgboost)               | XGBoost             | 0.376    | 0.308   | 6.904    | 0.15   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | XGBoost RF          | 0.391    | 0.329   | 7.392    | 0.09   |
|                                  |                | Gradient_Boosting(catboost)                      | CatBoost            | 0.376    | 0.303   | 6.784    | 0.18   |
| Região Sudeste                   | Perda de 59,9% | Gradient_Boosting(scikit-learn)                  |                     | 0.515    | 0.400   | 9.007    | 0.39   |
|                                  |                | Extreme Gradient Boosting(xgboost)               |                     | 0.539    | 0.421   | 9.458    | 0.34   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | 150                 | 0.539    | 0.467   | 10.458   | 0.14   |
|                                  |                | Gradient_Boosting(catboost)                      |                     | 0.512    | 0.421   | 8.455    | 0.37   |
| Estado de SP                     | Perda de 80%   | Gradient_Boosting(scikit-learn)                  |                     | 0.512    | 0.393   | 8.815    | 0.37   |
|                                  |                | Extreme Gradient Boosting(xgboost)               |                     | 0.537    | 0.417   | 9.230    | 0.31   |
|                                  |                | Extreme Gradient Boosting Random Forest(xgboost) | 150                 | 0.555    | 0.460   | 10.116   | 0.18   |
|                                  |                | Gradient_Boosting(catboost)                      |                     | 0.532    | 0.418   | 9.268    | 0.32   |

## Validação final:

Predito vs Real  
 $R^2=0.25$  |  $RMSE=0.356$



**$R^2$  0,47**

≈ 46% da variação do IDEB explicada


**RMSE 0,35**

erro típico de  $\pm 0,5$  ponto

**Estável**

Gradient boosting sklearn (200 trees)

## Validação final: erro típico de $\pm 0,5$ ponto



**$R^2$  0,47**

≈ 46% da variação do IDEB explicada


**RMSE 0,35**

erro típico de  $\pm 0,5$  ponto

**Estável**


Gradient boosting sklearn (200 trees)

# Do dado ao rótulo: o caminho do tratamento



- Resultado: 4 classes efetivas (II, MI, MM e MS). SS ( $\geq 9,0$ ) e SR (sem nota) não ocorrem na base.
- Validação: o boxplot do IDEB por rótulo confirma que os cortes separam as faixas.
- Saída: dados\_tratados\_classificacao.csv (17.583 × 228).

# A distribuição explica o desbalanceamento



**76,9%**


das escolas estão em uma única classe (MI)

**16%**

têm IDEB entre 4,8 e 5,2, colado no corte entre MI e MM

- Média 4,44 e desvio 0,71: a nota se concentra perto do centro.
- O corte em 5,0 separa escolas quase idênticas.

## Cinco algoritmos treinados e testados no Orange



- Métricas avaliadas: acurácia, F1 (macro e weighted), precisão e recall.
- Com classes desbalanceadas, a acurácia sozinha engana: o F1 macro mostra o desempenho em todas as classes.
- O Gradient Boosting foi o modelo escolhido e salvo para a análise de resultados.

# Gradient Boosting: acurácia de 81%, mas engana

81%

acurácia

0,45

F1 macro

≈ 77%



chute: sempre  
MI

| Classe | Recall | Precisão | Escolas |
|--------|--------|----------|---------|
| MI     | 95%    | 83%      | 4.054   |
| MM     | 36%    | 69%      | 1.127   |
| II     | 19%    | 45%      | 81      |
| MS     | 17%    | 15%      | 12      |

- Maior confusão: MM → MI (714 casos), entre classes vizinhas.
- O modelo aprende a classe dominante; nas minoritárias há poucos exemplos.

| Model             | AUC   | CA    | F1    | Prec  | Recall | MCC   |
|-------------------|-------|-------|-------|-------|--------|-------|
| Naive Bayes       | 0.664 | 0.518 | 0.607 | 0.753 | 0.518  | 0.186 |
| SVM               | 0.580 | 0.597 | 0.618 | 0.654 | 0.597  | 0.043 |
| Random Forest     | 0.769 | 0.798 | 0.758 | 0.774 | 0.798  | 0.322 |
| Gradient Boosting | 0.802 | 0.804 | 0.776 | 0.784 | 0.804  | 0.366 |
| Neural Network    | 0.747 | 0.771 | 0.760 | 0.753 | 0.771  | 0.317 |

# Gradient Boosting: 81% de acurácia, mas desempenho desigual entre as classes



# O que aprendemos

## Aprendizados

- Qualidade dos dados exigiu mais trabalho do que a modelagem
- O Censo explica **~46% da variação** do IDEB: o restante está fora da base
- Modelos de árvore venceram nas duas abordagens

## Próximos passos

- Tratar o desbalanceamento (SMOTE, class\_weight)
- Incluir o histórico do IDEB (2017–2023) como feature
- Analisar a importância das variáveis para orientar gestores

**Infraestrutura e perfil da escola explicam parte do IDEB, mas desempenho escolar é multifatorial.**

# Obrigado!

Perguntas?

github

